Actividad 6

¿Qué identificadores directos fueron eliminados?

Se eliminaron los identificadores directos que podrían identificar de manera única a una persona, como nombre, rfc, correo y teléfono. En la consulta únicamente se utilizan datos agrupados de edad y región, sin mostrar registros individuales.

¿Qué cuasi-identificadores permanecen?

Permanecen la edad y la ubicación geográfica. Estos atributos, por sí solos, no identifican directamente a una persona, pero podrían hacerlo al combinarse con otras fuentes de información.

¿Qué combinaciones de atributos podrían reducir el anonimato?

La combinación de rango de edad + región reduce el riesgo de identificación. Si se agregaran otros atributos como género, el riesgo de identificación aumentaría.

¿Qué sucede cuando un grupo contiene pocos registros?

Cuando un grupo tiene pocos registros, aumenta el riesgo de que una persona pueda ser identificada indirectamente. Por esta razón se utiliza count, que excluye grupos demasiado pequeños y mejora la protección de privacidad.

¿Qué atributos deberían generalizarse?

Deberían generalizarse aquellos que puedan actuar como cuasi-identificadores, por ejemplo: edad, código postal,  fecha de nacimiento etc.

¿Qué información debería suprimirse?

Deberían suprimirse: nombre, correo, teléfono, ID, grupos con muy pocos registros, valores atípicos que permitan distinguir a una persona, información detallada que no sea necesaria para el análisis.

¿Es correcto afirmar que el conjunto de datos es “100 % anónimo”? ¿Por qué?

No. La anonimización reduce significativamente el riesgo, pero en la práctica no suele ser posible garantizar un anonimato absoluto del 100 %.

La consulta modificada

```
SELECT
  CASE
    WHEN edad BETWEEN 18 AND 45 THEN '18-45'
    ELSE '46+'
  END AS rango_edad,
  LEFT(codigo_postal, 1) AS region,
  COUNT(*) AS total
FROM clientes
GROUP BY 1, 2
HAVING COUNT(*) >= 10;
```

**Cambios realizados**

- Uní los rangos de edad 18-30 y 31-45 en un único rango 18-45.
- Reduje la precisión de la ubicación utilizando solo el primer dígito del código postal (LEFT (codigo_postal, 1)).
- Aumente el umbral de anonimización de COUNT (*) >= 5 a COUNT (*) >= 10.

**2. Motivo**

- Los grupos de edad más amplios contienen más personas y dificultan distinguir individuos específicos.
- Exigir un mínimo de 10 registros por grupo aumenta el anonimato y disminuye la singularidad de los datos.

**3. Resultado obtenido**

- Cada combinación de edad y región representa al menos 10 personas.
- Se conserva la utilidad estadística para análisis generales, pero con menor exposición de información sensible.

**4. Riesgo que se pretende reducir**

- **Reidentificación de individuos** en regiones con poca población.
- **Singularización de registros** cuando existen grupos muy pequeños.